

Отчёт по проекту

Автоматизация ML-пайплайна на датасете Breast Cancer Wisconsin Diagnostic

Дисциплина: «Автоматизация машинного обучения»

Преподаватель: Елена Смысловских

Студент: Фабрикант Владислав

CitHub-репозиторий: <https://github.com/framey1/automl-project>

1. Описание проекта и бизнес-задачи

Цель проекта — автоматизировать полный ML-пайплайн для задачи бинарной классификации: по числовым признакам клеточных ядер определить класс опухоли. Проект демонстрирует практический MLOps-процесс: ETL, автоматический подбор модели, оценку качества, сохранение артефактов, тестирование, Docker, CI/CD и мониторинг.

Бизнес-смысл: подобный пайплайн может быть использован как демонстрационная система поддержки принятия решений. Модель не заменяет специалиста, но показывает, как можно автоматизировать подготовку данных и регулярное переобучение модели.

2. Данные

Использован датасет Breast Cancer Wisconsin Diagnostic, встроенный в библиотеку scikit-learn. Датасет содержит 569 объектов, 30 числовых признаков и целевую переменную target. Задача является бинарной классификацией.

Параметр	Значение
Количество объектов	569
Количество признаков	30
Целевая колонка	target
Тип задачи	Бинарная классификация

3. Схема пайплайна

- Extract: загрузка датасета через `sklearn.datasets.load_breast_cancer` и сохранение CSV.
- Transform: проверка данных, обработка пропусков, разделение на train/test.
- AutoML: автоматический перебор моделей и гиперпараметров через GridSearchCV.
- Evaluate: расчёт Accuracy, Precision, Recall, F1-score и ROC-AUC.
- Load: сохранение модели, метрик, processed-данных и графиков.
- Monitoring: логирование параметров эксперимента, метрик качества модели и артефактов запуска в MLflow и JSON.
- CI/CD: запуск тестов и пайплайна через GitHub Actions.

4. Описание ETL

Extract

Модуль `src/etl.py` загружает исходные данные и сохраняет их в `data/raw/breast_cancer.csv`.

Transform

Выполняется проверка корректности данных, проверка отсутствия пропусков и стратифицированное разделение на обучающую и тестовую выборку.

Load

Обработанные выборки сохраняются в `data/processed/`: `X_train.csv`, `X_test.csv`, `y_train.csv`, `y_test.csv`.

5. AutoML / автоматизация обучения модели

В проекте реализован автоматизированный подбор модели и гиперпараметров на базе `scikit-learn` и `GridSearchCV`. Выполняется последовательное сравнение нескольких алгоритмов и выбор лучшей конфигурации по метрике F1-score.

- Logistic Regression
- Random Forest
- Support Vector Classifier
- Gradient Boosting


Лучшая модель в текущем запуске: `logistic_regression`. Лучший CV F1-score: 0.9845.

6. Метрики модели


Метрика	Значение
accuracy	0.9825
precision	0.9861
recall	0.9861
f1	0.9861
roc_auc	0.9957

7. Визуализации


Распределение классов




Матрица ошибок



ROC-кривая



Важность признаков



8. Тестирование

Тестирование реализовано через pytest. Команда запуска: `pytest -q`.

Покрываются проверки загрузки датасета, наличия целевой колонки, корректности train/test split и возможности модели делать предсказания.

9. Docker

Контейнеризация реализована через Dockerfile. Контейнер нужен для воспроизводимого запуска проекта в одинаковом окружении.

Сборка: `docker build -t automl-project`.

Запуск: `docker run --rm automl-project`

10. CI/CD

CI/CD реализован через GitHub Actions в файле `.github/workflows/ci.yml`. При отправке изменений в репозиторий автоматически выполняются установка зависимостей, запуск тестов и запуск пайплайна обучения модели.

Использованные git-команды: `git init`, `git add .`, `git commit` и `git push` в `main`.

11. Мониторинг

Мониторинг реализован посредством MLflow. Во время обучения сохраняются параметры эксперимента, метрики качества модели и артефакты запуска. Дополнительно формируется файл `monitoring_record.json`.

Логируются метрики модели, выбранный алгоритм, лучшие гиперпараметры и CV-score. Для просмотра MLflow используется команда `mlflow ui`.

12. GitHub-репозиторий

Проект опубликован в GitHub-репозитории и содержит исходный код, структуру ML-пайплайна, Docker-конфигурацию, CI/CD и документацию проекта.

Репозиторий:

<https://github.com/frameyl/automl-project>

13. Выводы

В результате выполнения проекта был разработан и реализован автоматизированный процесс обучения и оценки ML-модели для задачи бинарной классификации. Построен полный цикл обработки данных: загрузка и подготовка датасета (ETL), автоматизированный подбор модели и гиперпараметров, оценка качества, сохранение результатов, мониторинг экспериментов через MLflow, контейнеризация с использованием Docker и автоматизация проверки через CI/CD.